

Apêndice A — Dicionário das Variáveis Seleccionadas

Tabela A1. Dicionário das Variáveis Seleccionadas.

Categoria	Variável	Descrição
Demográfica	NU_IDADE_N	Idade do paciente
Demográfica	CS_SEXO	Sexo biológico
Demográfica	CS_RACA	Raça declarada
Demográfica	CS_ESCOL_N	Escolaridade
Demográfica	ID_OCUPA_N	Ocupação do paciente
Epidemiológica	ANT_CB_LAM	Contato com lama
Epidemiológica	ANT_CB_CRI	Contato com criação de animais
Epidemiológica	ANT_CB_SIN	Presença de sinantrópicos
Epidemiológica	ANT_CB_COR	Contato com córregos/lagoas
Epidemiológica	ANT_CB_ROE	Presença de roedores
Epidemiológica	ANT_CB_TER	Contato com terra/barro
Epidemiológica	ANT_CB_LIX	Contato com lixo
Epidemiológica	ANT_CB_OUT	Outras exposições ambientais
Epidemiológica	ANT_ANIMAI	Contato com animais
Epidemiológica	ANT_HUMANO	Contato com humanos infectados
Clínica	CLI_FEBRE	Presença de febre
Clínica	CLI_MIALGI	Presença de mialgia
Clínica	CLI_CEFAL	Presença de cefaleia
Clínica	CLI_PROST	Presença de prostração
Clínica	CLI_CONGES	Congestão conjuntival
Clínica	CLI_PANTUR	Dor em panturrilhas
Clínica	CLI_VOMITO	Presença de vômitos
Clínica	CLI_DIARRE	Presença de diarreia
Clínica	CLI_ICTERI	Presença de icterícia
Clínica	CLI_RENAL	Insuficiência renal
Clínica	CLI_RESPIR	Comprometimento respiratório
Clínica	CLI_CARDIA	Alterações cardíacas
Clínica	CLI_HEMOPU	Hemoptise
Clínica	CLI_HEMORR	Manifestações hemorrágicas
Clínica	CLI_MENING	Meningite
Clínica	CLI_OUTROS	Outros sinais clínicos
Socioeconômica derivada	baixa_escolaridade	Indicador de baixa escolaridade
Socioeconômica derivada	raca_vulneravel	Indicador de vulnerabilidade racial
Socioeconômica derivada	faixa_vulneravel	Faixa etária vulnerável
Socioeconômica derivada	vulnerabilidade_social	Indicador composto de vulnerabilidade social
Socioeconômica derivada	nivel_vulnerabilidade	Índice ordinal de vulnerabilidade
Temporal derivada	mes_sintomas	Mês de início dos sintomas
Temporal derivada	estacao	Estação do ano
Temporal derivada	periodo_chuvoso	Indicador de período chuvoso

Apêndice B — Espaço de busca dos hiperparâmetros

Tabela B1. Espaço de busca dos hiperparâmetros utilizados na otimização dos modelos Random Forest, SVM, XGBoost e LightGBM.

Parâmetro	Random Forest	SVM (LinearSVC)	XGBoost	LightGBM
<i>n_estimators</i>	5 – 30	—	5 – 30	5 – 30
<i>max_depth</i>	3 – 9	—	3 – 9	3 – 9
<i>learning_rate</i>	—	—	0,01 – 0,30	0,01 – 0,30
<i>subsample</i>	—	—	0,5 – 1,0	0,5 – 1,0
<i>colsample_bytree</i>	—	—	0,5 – 1,0	0,5 – 1,0
<i>min_samples_split</i>	2 – 10	—	—	—
<i>min_samples_leaf</i>	1 – 5	—	—	—
<i>C</i>	—	0,1 – 3,0	—	—
<i>max_iter</i>	—	5000	—	—
<i>class_weight</i>	balanced	balanced	—	—
<i>scale_pos_weight</i>	—	—	razão entre classes	—
<i>is_unbalance</i>	—	—	—	True
<i>force_col_wise</i>	—	—	—	True
<i>eval_metric</i>	—	—	logloss	—
<i>n_jobs</i>	—	—	-1	—
Calibração de probabilidade	—	sigmoid (Platt scaling)	—	—

Tabela B2. Configurações das técnicas de balanceamento de classes avaliadas durante o processo de otimização dos modelos de classificação supervisionada.

Parâmetro	<i>Random OverSampling</i>	<i>Random UnderSampling</i>	<i>SMOTE</i>
<i>sampling_mode</i>	<i>over</i>	<i>under</i>	<i>smote</i>
<i>sampling_strategy</i>	<i>auto</i>	<i>auto</i>	<i>minority</i>
<i>k_neighbors</i>	—	—	3 – 10

Apêndice C — Análise Exploratória das Variáveis do SINAN

C.1 Análise das variáveis demográficas, clínicas e epidemiológicas

Antes da etapa de modelagem preditiva, foi conduzida uma análise exploratória das variáveis demográficas, clínicas e epidemiológicas presentes na base do SINAN, com o objetivo de compreender a distribuição dos registros, identificar padrões relevantes associados à confirmação diagnóstica e à gravidade dos casos, além de subsidiar o processo de engenharia de atributos.

A análise foi estruturada em três grupos principais: variáveis demográficas, variáveis clínicas e variáveis epidemiológicas.

C.1.1 Variáveis Demográficas

A análise das variáveis demográficas teve como objetivo caracterizar o perfil populacional dos casos de leptospirose registrados na base do SINAN, considerando sexo, faixa etária e nível de escolaridade, além da distribuição da letalidade segundo grupos etários.

A distribuição dos casos confirmados de leptospirose segundo sexo evidenciou predominância significativa do sexo masculino, representando aproximadamente 68,6% dos registros, enquanto indivíduos do sexo feminino corresponderam a cerca de 31,4% dos casos (Figura C1). Esse padrão é amplamente descrito na literatura epidemiológica da leptospirose e está associado, principalmente, à maior exposição ocupacional e ambiental entre homens.




Figura C1. Distribuição percentual dos casos confirmados de leptospirose segundo sexo registrados no SINAN/SUS no período de 2015 a 2024.

A distribuição etária indicou maior concentração de casos nas faixas entre 31 e 50 anos, seguidas pelos grupos de 19 a 30 anos e 51 a 65 anos (Figura C2). Observa-se menor frequência relativa em crianças e adolescentes, bem como em indivíduos com idade superior a 65 anos.



Figura C2. Distribuição dos casos de leptospirose segundo faixa etária registrados no SINAN/SUS no período de 2015 a 2024.

A análise da escolaridade revelou maior concentração de casos entre indivíduos com nível de ensino médio completo e ensino fundamental incompleto ou completo (Figura C3). Observa-se menor proporção de casos entre indivíduos com ensino superior completo, o que pode refletir diferenças estruturais no acesso a ambientes menos expostos a fatores de risco ambientais.




Figura C3. Distribuição dos casos de leptospirose segundo nível de escolaridade registrados no SINAN/SUS no período de 2015 a 2024.

A distribuição da letalidade por faixa etária evidenciou aumento progressivo do risco de óbito com o avanço da idade (Figura C4). Enquanto indivíduos mais jovens apresentaram taxas reduzidas de letalidade, observou-se elevação expressiva a partir dos 51 anos, atingindo aproximadamente 19,9% entre indivíduos com mais de 65 anos. Esse comportamento é compatível com evidências clínicas que indicam maior risco de evolução para formas graves da leptospirose em idosos, possivelmente em decorrência da presença de comorbidades, menor reserva fisiológica e maior susceptibilidade a complicações sistêmicas associadas à doença.




Figura C4. Taxa de letalidade por leptospirose segundo faixa etária registrada no SINAN/SUS no período de 2015 a 2024.

De forma geral, os resultados observados nas variáveis demográficas mostram elevada coerência com o perfil epidemiológico descrito na literatura nacional e internacional, reforçando a consistência da base utilizada e a relevância dessas variáveis como potenciais preditores nos modelos de classificação supervisionada propostos neste estudo.

C.1.2 Variáveis Clínicas

A análise das variáveis clínicas permitiu caracterizar a frequência dos principais sinais e sintomas registrados no momento da notificação e avaliar sua associação com quadros graves e desfechos desfavoráveis da leptospirose. Observou-se elevada frequência de sintomas inespecíficos, com destaque para febre (83,5%), mialgia (77,3%) e cefaleia (68,5%), seguidos por prostração (50,3%), dor em panturrilhas (45,9%) e vômitos (43,0%) (Figura C5). Esses achados são compatíveis com a fase inicial da doença e reforçam a dificuldade diagnóstica baseada exclusivamente em manifestações clínicas isoladas [Brasil 2014; Li et al. 2022].




Figura C5. Frequência percentual dos principais sintomas clínicos em casos de leptospirose registrados no SINAN/SUS no período de 2015 a 2024.

Entre os casos classificados como graves, observou-se maior frequência de manifestações clássicas da Síndrome de Weil, especialmente icterícia (30,63%) e insuficiência renal (14,64%), além de manifestações hemorrágicas e hemoptise (Figura C6). Esses resultados estão alinhados com a literatura clínica, que descreve a combinação entre icterícia, disfunção renal e manifestações hemorrágicas como um dos principais marcadores de evolução desfavorável na leptospirose [Costa et al. 2015; Li et al. 2022].




Figura C6. Frequência dos principais marcadores clínicos associados à Síndrome de Weil em casos classificados como graves de leptospirose registrados no SINAN/SUS no período de 2015 a 2024.

A análise comparativa da letalidade entre casos graves e não graves evidenciou diferença expressiva entre os grupos, com taxa de letalidade de aproximadamente 20,49% entre casos graves e 6,34% entre casos não graves (Figura C7). Esse resultado confirma a forte associação entre manifestações clínicas sistêmicas e pior prognóstico, destacando a importância da identificação precoce de sinais de gravidade durante a triagem clínica. A magnitude dessa diferença reforça a utilidade da variável derivada de severidade construída neste estudo como indicador relevante para apoio à decisão clínica.




Figura C7. Comparação da taxa de letalidade entre casos graves e não graves de leptospirose registrados no SINAN/SUS no período de 2015 a 2024.

Por fim, a distribuição temporal dos óbitos por leptospirose indicou maior concentração de eventos fatais nos primeiros dias após o início dos sintomas, com aproximadamente 46,6% ocorrendo em até sete dias e 30,3% entre oito e quatorze dias (Figura C8).




Figura C8. Distribuição temporal dos óbitos por leptospirose segundo o intervalo de dias desde o início dos sintomas registrados no SINAN/SUS no período de 2015 a 2024.

Observa-se redução progressiva da frequência de óbitos após duas semanas de evolução clínica, sugerindo que o período inicial da doença representa a fase de maior risco para desfechos desfavoráveis. Esse padrão é consistente com a evolução clínica descrita na literatura, segundo a qual complicações graves tendem a ocorrer precocemente, especialmente na ausência de diagnóstico oportuno e intervenção terapêutica adequada [Brasil 2014; Costa et al. 2015].

De forma geral, os resultados observados nas variáveis clínicas evidenciam coerência com o espectro clínico clássico da leptospirose e reforçam a relevância dessas variáveis para a identificação precoce de casos com maior risco de evolução desfavorável, contribuindo para a fundamentação da estratégia de modelagem preditiva adotada neste estudo.

C.1.3 Variáveis Epidemiológicas

A análise das variáveis epidemiológicas teve como objetivo caracterizar os principais contextos de exposição associados aos casos suspeitos de leptospirose registrados no SINAN, considerando fatores ambientais, domiciliares e ocupacionais relacionados ao risco de infecção.

A distribuição dos tipos de exposição evidenciou maior frequência de fatores associados ao ambiente domiciliar e periurbano, com destaque para a presença de sinantrópicos (50,93%), contato com lama (35,10%), criação de animais (28,81%) e exposição a lixo (25,43%) (Figura C9). Observou-se também frequência relevante de exposição a córregos ou lagoas (24,50%), terra ou barro (22,34%) e presença de roedores (22,12%), fatores classicamente descritos como componentes centrais na cadeia de transmissão da leptospirose. Esses resultados refletem a forte relação entre a ocorrência

da doença e condições ambientais precárias, especialmente em áreas com saneamento insuficiente e maior suscetibilidade a enchentes [Pappas et al. 2008].



Figura C9. Distribuição percentual dos principais tipos de exposição associados aos casos de leptospirose registrados no SINAN/SUS no período de 2015 a 2024.

A análise da letalidade segundo o tipo de exposição indicou variações entre os diferentes contextos ambientais investigados, com taxas superiores à média geral (8,97%) observadas em exposições classificadas como “outros” (9,25%), contato com lixo (9,24%), fossas (8,77%), roedores (8,21%) e lama (8,19%) (Figura C10). Esses achados sugerem que determinados ambientes podem estar associados a maior risco de evolução desfavorável, possivelmente em decorrência de maior carga bacteriana, atraso na identificação clínica ou maior intensidade da exposição ao agente infeccioso. Em contraste, exposições relacionadas à criação de animais (4,96%), granjas (4,48%) e plantas ou vegetação (4,43%) apresentaram menores taxas relativas de letalidade.




Figura C10. Taxa de letalidade por leptospirose segundo tipo de exposição registrada no SINAN/SUS no período de 2015 a 2024.

A comparação entre exposições ocupacionais e não ocupacionais evidenciou diferenças importantes no perfil de risco entre os grupos analisados (Figura C11).




Figura C11. Comparação entre exposições ocupacionais e não ocupacionais associadas aos casos de leptospirose registrados no SINAN/SUS no período de 2015 a 2024.

Observou-se maior predominância de exposições ocupacionais associadas a atividades envolvendo terra ou barro, fossas, granjas e manejo de animais, enquanto exposições não ocupacionais apresentaram maior frequência relativa em contextos urbanos, como contato com lixo, presença de roedores e ambientes alagados. Esse padrão reforça o caráter multifatorial da transmissão da leptospirose no Brasil, evidenciando que tanto atividades profissionais quanto condições ambientais domiciliares contribuem para a ocorrência da doença [Costa et al. 2015; Li et al. 2022].

Apêndice D — Resultados de validação interna e importância de variáveis

Tabela 1. Desempenho médio dos modelos na validação cruzada interna para classificação entre casos descartados e confirmados, avaliado por meio da métrica AUC, com e sem seleção de variáveis.

Abordagem	LightGBM	XGBoost	SVM	Random Forest
Descartados e Confirmados com Seleção de Variável	0.9088 ± 0.0016	0.9054 ± 0.0043	0.9026 ± 0.0010	0.8905 ± 0.0237
Descartados e Confirmados sem Seleção de Variável	0.9272 ± 0.0040	0.9163 ± 0.0201	0.9187 ± 0.0014	0.9010 ± 0.0148

Tabela 2. Desempenho médio dos modelos na validação cruzada interna para classificação de severidade clínica (grave vs. não grave), avaliado por meio da métrica AUC, com e sem seleção de variáveis.

Abordagem	LightGBM	XGBoost	SVM	Random Forest
Severidade binária sem Seleção de Variável	0.7082 ± 0.0079	0.7013 ± 0.0117	0.6995 ± 0.0046	0.6906 ± 0.0099
Severidade binária com Seleção de Variável	0.6974 ± 0.0070	0.6915 ± 0.0129	0.6891 ± 0.0028	0.6804 ± 0.0146

Tabela 3. Tempo médio de treinamento (em segundos) dos modelos avaliados na tarefa de classificação entre casos Descartados e Confirmados, com e sem aplicação de seleção de variáveis.

Abordagem	LightGBM	XGBoost	SVM	Random Forest
Descartados e Confirmados com Seleção de Variável	13.8 ± 1.5	15.5 ± 2.6	33.3 ± 6.8	13.5 ± 1.5
Descartados e Confirmados sem Seleção de Variável	29.3 ± 2.6	34.0 ± 6.8	146.6 ± 38.3	29.9 ± 4.8

Tabela 4. Tempo médio de treinamento (em segundos) dos modelos avaliados na tarefa de classificação de severidade clínica (grave vs. não grave), com e sem aplicação de seleção de variáveis.

Abordagem	LightGBM	XGBoost	SVM	Random Forest
Severidade binária com Seleção de Variável	5.7 ± 7.0	7.2 ± 7.4	19.1 ± 11.8	7.5 ± 6.8
Severidade binária sem Seleção de Variável	15.1 ± 14.3	12.4 ± 13.5	45.5 ± 26.1	12.6 ± 13.1

Tabela 5. Importância média das variáveis preditoras na classificação entre casos confirmados e descartados de leptospirose utilizando o modelo LightGBM

Variável	Importância média	Desvio Padrão
ID_OCUPA_N	211.25	5.678908
CS_ESCOL_N	112.75	14.384598
ANT_CB_LAM	79.25	4.112988
NU_IDADE_N	78.50	8.850612
CLI_ICTERI	76.50	13.329166
CON_AMBIEN	63.50	6.608076
CLI_PANTUR	53.75	4.991660
CON_AREA	52.75	2.500000
CLI_OUTROS	32.00	6.976150
CLI_PROST	26.50	5.446712
vulnerabilidade_social	10.75	3.403430
nivel_vulnerabilidade	6.25	2.629956
periodo_chuvoso	6.25	2.061553

Tabela 6. Importância média das variáveis preditoras na classificação da severidade clínica (grave vs. não grave) utilizando o modelo LightGBM.

Variável	Importância média	Desvio Padrão
SG_UF	91.75	6.500000
CLI_PROST	43.75	5.909033
NU_IDADE_N	37.25	7.410578
CLI_CONGES	31.25	7.274384
ID_OCUPA_N	26.25	6.448514
CS_ESCOL_N	26.00	4.242641
CLI_OUTROS	24.75	5.560276
ANT_CB_SIN	21.00	6.000000
CLI_PANTUR	20.25	3.774917
CON_AREA	18.00	7.257180
CLI_CEFAL	16.00	3.915780
CON_AMBIEN	13.75	9.945686
ANT_CB_LAM	10.00	5.099020
vulnerabilidade_social	8.75	1.500000
ANT_CB_CRI	6.50	1.914854
nivel_vulnerabilidade	5.00	0.816497




Figura 1. Curvas ROC validação externa LightGBM para casos confirmados.




Figura 2. Curvas ROC validação externa LightGBM para severidade.




Figura 3. Curvas Precision–Recall do modelo LightGBM em validação externa para casos confirmados.




Figura 4. Curvas Precision–Recall do modelo LightGBM em validação externa para severidade.




Figura 5. Curvas de variação das quantidades de falsos positivos (FP) e falsos negativos (FN) em função do limiar de decisão para classificação entre casos descartados e confirmados de leptospirose ao longo das partições da validação cruzada externa.




Figura 6. Curvas de falsos positivos e falsos negativos em função do limiar de decisão para severidade.




Figura 7. Curvas de calibração do modelo LightGBM em validação externa para casos confirmados.




Figura 8. Curvas de calibração do modelo LightGBM em validação externa para severidade.