

Modelo Preditivo Para Apoio à Triage de Leptospirose a Partir De Dados do SINAN/SUS

Ana Carolyne Pereira¹, Diego Pereira Lima¹, Lilian Berton¹

¹Specialization Course in Data Science – Instituto Tecnológico de Aeronáutica (ITA)
Praça Mal. Eduardo Gomes 50 – São José dos Campos – SP – Brasil

{Ana.pereira.20818, diego.lima.20829}@ga.ita.br,
lilian.berton@gp.ita.br

Abstract. *This study proposes a predictive model to support the clinical triage of suspected leptospirosis cases using data from the Notifiable Diseases Information System (SINAN), based on clinical, demographic, and epidemiological variables. The LightGBM model achieved the best performance in classifying confirmed versus discarded cases ($AUC \approx 0.93$) and moderate performance in predicting clinical severity ($AUC \approx 0.70$). Threshold analysis indicated that values below 0.5 are more appropriate for prioritizing sensitivity and reducing false negatives in triage settings. The results highlight the model's potential as a decision-support tool for epidemiological surveillance and clinical prioritization within the Brazilian Unified Health System (SUS).*

Resumo. *Este estudo propõe um modelo preditivo para apoiar a triagem clínica de leptospirose utilizando dados do Sistema de Informação de Agravos de Notificação, com base em variáveis clínicas, demográficas e epidemiológicas. O modelo LightGBM apresentou melhor desempenho na classificação entre casos confirmados e descartados ($AUC \approx 0.93$) e desempenho moderado na predição da severidade clínica ($AUC \approx 0.70$). A análise do limiar de decisão indicou maior adequação de thresholds inferiores a 0,5 para priorizar sensibilidade e reduzir falsos negativos em contexto de triagem. Os resultados evidenciam o potencial do modelo como ferramenta de apoio à decisão na vigilância epidemiológica e na priorização clínica no Sistema Único de Saúde.*

1. Introdução

1.1. Contextualização e Motivação

A leptospirose é uma zoonose de distribuição global e relevante problema de saúde pública, especialmente em países tropicais e contextos de vulnerabilidade socioambiental [Pappas et al. 2008]. No Brasil, apresenta caráter endêmico, com aumento de casos em períodos chuvosos, associado a enchentes, saneamento deficiente, presença de roedores e exposição ocupacional ou ambiental à água e ao solo contaminados [Brasil. Ministério da Saúde 2024].

A infecção humana varia de quadros leves e inespecíficos a formas graves, incluindo insuficiência renal aguda, manifestações hemorrágicas, comprometimento respiratório e síndrome de Weil. Essa variabilidade dificulta o diagnóstico precoce e contribui para elevada morbimortalidade, sobretudo quando há atraso no reconhecimento da gravidade e no início do tratamento [Costa et al. 2015; Li et al. 2022].

No Brasil, o Sistema Único de Saúde (SUS) possui ampla cobertura populacional, mas enfrenta desafios operacionais em contextos de alta demanda e recursos limitados. Nesse cenário, a incorporação de ferramentas computacionais de apoio à decisão clínica ainda ocorre de forma heterogênea, variando conforme infraestrutura e capacidade analítica regional [Brasil. Ministério da Saúde 2023; Da Silva et al. 2014; Lima et al. 2009].

Apesar da disponibilidade de bases geradas pelos sistemas de informação em saúde, o uso de aprendizado de máquina permanece limitado, principalmente devido a problemas de qualidade e padronização dos dados, embora estudos recentes já evidenciem seu potencial em análises preditivas em saúde pública [Reinheimer et al. 2025].

No âmbito da vigilância epidemiológica, os casos suspeitos de leptospirose são registrados no Sistema de Informação de Agravos de Notificação (SINAN), que reúne dados clínicos, demográficos e epidemiológicos relevantes [Brasil. Ministério da Saúde 2016]. Contudo, essas informações ainda são pouco exploradas de forma sistemática na triagem clínica, mantendo decisões dependentes da experiência individual do profissional de saúde, o que pode gerar variabilidade na avaliação de risco, subpriorização de casos graves e uso ineficiente de recursos assistenciais [Brasil 2014].

Sob a perspectiva da ciência de dados, persiste a lacuna de transformar bases heterogêneas, com valores ausentes, ruído e desbalanceamento entre classes, em estimativas de risco confiáveis e acionáveis. Nesse contexto, modelos supervisionados, especialmente abordagens baseadas em *ensemble learning* e métodos de *gradient boosting*, destacam-se por sua robustez a dados incompletos, relações não lineares e interações entre variáveis, configurando-se como alternativas promissoras para apoiar a decisão clínica e operacional em saúde pública [Chen and Guestrin 2016].

1.2. Questão de Pesquisa

Diante do contexto apresentado na seção 1.1, o problema endereçado nesta pesquisa consiste em: **Como apoiar a priorização da confirmação de casos suspeitos de leptospirose e o grau de severidade no contexto da triagem clínica?**

1.3. Objetivo Geral

Propor um modelo de classificação supervisionada baseado em aprendizado de máquina para apoiar a confirmação de casos suspeitos de leptospirose e estratificação do grau de severidade utilizando variáveis demográficas, clínicas e epidemiológicas provenientes do SINAN/SUS de 2015 a 2024, com foco na redução de falsos negativos.

1.4. Objetivos Específicos

- Analisar variáveis clínicas, demográficas e epidemiológicas de casos de leptospirose do SINAN/SUS, para apoiar a engenharia de atributos.
- Estruturar um pipeline de pré-processamento e seleção de variáveis orientada a performance e o custo de processamento.
- Treinar e avaliar o modelo de classificação supervisionada, para diferentes configurações de hiperparâmetros, alinhado a melhor capacidade de generalização e eficiência computacional.

- Ajustar o limiar de classificação (*threshold*) para priorizar a sensibilidade do modelo, visando a redução crítica de falsos negativos na triagem.
- Analisar a importância das variáveis explicativas, discutindo a aplicabilidade do modelo como ferramenta de apoio à decisão na triagem do SUS.

2. Revisão Rápida da Literatura

O uso de aprendizado de máquina na saúde tem se expandido em aplicações de predição clínica, diagnóstico e apoio à decisão. Em saúde pública, Mooney and Pejaver [2018] destacam seu potencial para predição de riscos em nível populacional, ao mesmo tempo em que apontam desafios recorrentes, como viés, valores ausentes, heterogeneidade dos dados e limitações de interpretabilidade em cenários reais.

No contexto da leptospirose, Jadhav [2025] em revisão sistemática sobre modelos de *machine learning* e *deep learning*, observaram bom desempenho dessas abordagens, mas ressaltaram limitações relevantes, como o predomínio de bases hospitalares privadas, uso limitado de validação robusta e baixa generalização, restringindo sua aplicação em nível populacional.

No Brasil, Silva et al. [2014] aplicaram aprendizado de máquina a dados do SINAN para predição de desfechos finais (cura ou óbito), com bom desempenho de modelos como *Random Forest* e *AdaBoost*. Entretanto, o estudo não contempla a etapa de triagem clínica nem o ajuste do *threshold* de decisão, aspecto crítico para redução de falsos negativos.

Bohm [2024], utilizando dados do SINAN do Rio Grande do Sul, aplicaram algoritmos como *Random Forest*, *Support Vector Machine* e redes neurais para classificação de casos suspeitos, obtendo desempenho moderado, atribuído à baixa qualidade dos dados, com valores ausentes, inconsistências e variáveis incompletas, evidenciando limitações recorrentes em bases de sistemas públicos de saúde.

Estudos voltados à predição de gravidade ou mortalidade, como Galdino et al. [2023], com dados hospitalares no Brasil, e Reagan et al. [2022], em contexto veterinário, apresentam resultados promissores, porém com aplicabilidade limitada à saúde pública devido à natureza específica das bases utilizadas.

De forma geral, embora modelos de aprendizado de máquina apresentem bom desempenho em tarefas preditivas, persistem lacunas em aplicações operacionais de triagem clínica, especialmente quanto ao uso de dados nacionais do SINAN com ajuste explícito do *threshold* de decisão voltado à redução de falsos negativos.

Diante disso, este trabalho propõe um modelo de classificação supervisionada para triagem clínica da leptospirose com dados do SINAN/SUS, incorporando engenharia de atributos, seleção de variáveis e ajuste do *trade-off* entre sensibilidade e especificidade, visando aproximar modelos preditivos da realidade operacional do sistema público e contribuir para a priorização mais eficiente de casos suspeitos.

3. Desenvolvimento

3.1 Obtenção dos Dados

Este estudo caracteriza-se como uma pesquisa observacional retrospectiva baseada em dados provenientes do SINAN/SUS [Brasil. Ministério da Saúde 2016]. A base original compreendeu aproximadamente 170 mil registros de casos suspeitos de leptospirose no Brasil, contendo informações clínicas, demográficas, epidemiológicas e de desfecho, referentes ao período de 2015 a 2024. Por se tratar de uma doença de notificação compulsória, os registros são realizados por meio da Ficha Individual de Notificação (FIN), instrumento estruturado que organiza as informações dos casos suspeitos no sistema de vigilância epidemiológica nacional.

A FIN é composta por 74 campos distribuídos entre dados gerais, notificação individual, residência, antecedentes epidemiológicos, informações clínicas, atendimento, dados laboratoriais e conclusão do caso. Os registros são disponibilizados publicamente via DataSUS em formato anonimizado, sem variáveis que permitam a identificação direta dos indivíduos, garantindo conformidade com os princípios de confidencialidade e privacidade previstos nos sistemas de informação em saúde pública [Ministério da Saúde 2026; Brasil. Ministério da Saúde 2016].

3.2 Seleção das Variáveis Preditivas

A seleção das variáveis preditoras foi orientada por evidências clínicas e epidemiológicas descritas na literatura sobre leptospirose, contemplando sinais e sintomas clássicos como febre, mialgia, cefaleia e vômitos, além de marcadores de gravidade, como icterícia, insuficiência renal e manifestações hemorrágicas, associados a pior prognóstico clínico [Brasil 2014; Li et al. 2022]. Considerando que nenhum sinal clínico isolado apresenta capacidade discriminativa suficiente, foram também incluídas variáveis demográficas e determinantes socioambientais, como exposição a enchentes, contato com água ou solo contaminado, presença de roedores e condições precárias de saneamento, refletindo o caráter multifatorial da transmissão da doença e contribuindo para a estratificação de risco em cenários de triagem [Brasil 2014; Bohm 2024; Costa et al. 2015]. O dicionário completo das variáveis selecionadas encontra-se no Apêndice A.

3.3 Pré-Processamento

O pré-processamento envolveu tratamento de valores ausentes, padronização do formato das variáveis e codificação adequada de atributos categóricos. Optou-se por preservar a maior quantidade possível de informação clínica relevante, evitando exclusões excessivas de registros, prática comum em bases de vigilância epidemiológica. Variáveis categóricas foram transformadas por meio de codificação apropriada para uso em algoritmos baseados em árvores, enquanto variáveis numéricas foram mantidas em suas escalas originais, respeitando a natureza do modelo final selecionado.

3.4 Formulação do Problema e Variável Alvo

O problema foi formulado como uma tarefa de classificação binária supervisionada, com foco em triagem clínica. A variável alvo (*target*) foi definida a partir do encerramento do caso no SINAN:

- Classe 1 (Positivo): Casos confirmados de leptospirose.

- Classe 0 (Negativo): Casos descartados.

Essa definição está alinhada ao objetivo do estudo de apoiar a identificação precoce de casos com maior probabilidade de confirmação, contribuindo para a priorização clínica em cenários de incerteza diagnóstica e limitações inerentes a sistemas de vigilância epidemiológica [Brasil. Ministério da Saúde 2016; Pongpan et al. 2023; Silva et al. 2014].

Como forma de enriquecer a representação clínica dos dados, foi construída uma variável derivada de severidade clínica, estruturada de forma binária, com base em manifestações sistêmicas registradas na base, incluindo icterícia, disfunção renal, alterações respiratórias, hemorragias, acometimento cardíaco, comprometimento do sistema nervoso central e síndrome de Weil, priorizando a identificação de quadros graves associados a maior risco de complicações, conforme descrito em protocolos clínicos e estudos sobre evolução da leptospirose [Bohm 2024; Brasil 2014].

- Classe 1 (Grave): Casos que apresentaram pelo menos um dos seguintes critérios: icterícia, insuficiência renal, comprometimento respiratório, hemorragia pulmonar e acometimento do sistema nervoso central.
- Classe 0 (Não Grave): Casos com manifestações clínicas isoladas ou ausência de critérios de comprometimento multissistêmico.

3.5 Tratamento do Desbalanceamento entre Classes

A variável alvo apresentou desbalanceamento moderado, com predominância de casos descartados (65% a 70%) em relação aos confirmados (30% a 35%), padrão esperado em sistemas de vigilância epidemiológica baseados em notificação compulsória. Para mitigar seus efeitos na identificação da classe minoritária, foram avaliadas diferentes estratégias de balanceamento durante a otimização dos modelos, incluindo *oversampling* aleatório, *undersampling* aleatório [He and Garcia 2009] e a técnica *Synthetic Minority Over-sampling Technique* (SMOTE) [Chawla et al. 2002], cujas configurações encontram-se descritas na Tabela B.2 do Apêndice B.

As técnicas de reamostragem foram aplicadas exclusivamente sobre os dados de treinamento em cada iteração da validação cruzada, integradas a um pipeline unificado para evitar vazamento de informação e preservar a capacidade de generalização, sendo complementadas por mecanismos internos de ajuste de desbalanceamento, como o parâmetro *scale_pos_weight* no XGBoost, contribuindo para maior robustez do modelo e melhoria da sensibilidade, métrica particularmente relevante no contexto clínico por reduzir a ocorrência de falsos negativos.

3.6 Redução de Dimensionalidade das Variáveis

A redução de dimensionalidade do conjunto de dados foi conduzida com o objetivo de identificar atributos com maior relevância preditiva, contribuindo para a melhoria da capacidade de generalização dos modelos e para a eficiência computacional do processo de modelagem. O processo foi estruturado com base em métodos selecionados por sua eficiência computacional e independência em relação ao modelo preditivo [Guyon and Elisseeff 2003]. Inicialmente, as variáveis foram separadas em numéricas e categóricas, sendo as primeiras padronizadas por meio de *StandardScaler* e as categóricas

transformadas em variáveis indicadoras (*dummy variables*), resultando em uma matriz numérica adequada à aplicação dos métodos de seleção [Senter 2008].

A seleção foi realizada após o pré-processamento, iniciando-se com a aplicação do filtro de baixa variância (*Variance Threshold*), seguida da utilização de métodos baseados na relação entre cada variável e a variável alvo, incluindo *Mutual Information*, capaz de capturar relações não lineares [Kraskov et al. 2004], e testes baseados em ANOVA (ou *F-regression*) [Senter 2008]. Em seguida, empregou-se um método *embedded* baseado em *Random Forest* para estimar a importância das variáveis. Por fim, a seleção final foi conduzida por um método no qual as variáveis foram avaliadas individualmente com base no desempenho preditivo em validação cruzada, resultando em um conjunto com maior capacidade de generalização [Guyon and Elisseeff 2003].

3.7 Modelagem Preditiva

Foram avaliados diferentes algoritmos de classificação supervisionada amplamente consolidados na literatura de aprendizado de máquina, incluindo *Random Forest* [Breiman 2001], *Support Vector Machines* (SVM) [Cortes and Vapnik 1995], *Extreme Gradient Boosting – XGBoost* [Chen and Guestrin 2016] e *Light Gradient Boosting Machine (LightGBM)* [Ke et al. 2017], contemplando distintos paradigmas de aprendizado, como métodos baseados em árvores, técnicas de margens e algoritmos de *boosting*, adequados para dados heterogêneos e potencialmente ruidosos. O espaço de busca dos hiperparâmetros encontra-se detalhado no Apêndice B, e os modelos foram implementados por meio de um *pipeline* estruturado que integrou etapas de pré-processamento, balanceamento e treinamento, incluindo imputação por mediana e padronização para variáveis numéricas, e imputação pela moda com codificação por *dummy variables* para variáveis categóricas [Senter 2008], evitando vazamento de informação. Adicionalmente, no modelo SVM foi aplicada calibração probabilística por método sigmoide para viabilizar o uso de métricas baseadas em probabilidade, como a *Area Under the ROC Curve* (AUC), enquanto nos modelos baseados em *boosting* foram otimizados hiperparâmetros relacionados à complexidade e regularização, como profundidade máxima das árvores, taxa de aprendizado e frações de amostragem, conforme proposto na literatura [Friedman 2001].

3.8 Estratégia de Validação

A avaliação dos modelos foi conduzida por meio de uma estratégia de *Nested Cross-Validation*, recomendada em cenários com otimização de hiperparâmetros por permitir a separação rigorosa entre as etapas de ajuste e avaliação, reduzindo o risco de sobreajuste [Berrar 2019]. Essa abordagem foi estruturada em dois níveis complementares: um nível externo (*outer loop*), responsável pela estimativa do desempenho generalizável, e um nível interno (*inner loop*), destinado à seleção de modelos e ajuste de hiperparâmetros.

No nível externo, foi empregada validação cruzada estratificada com quatro partições, preservando a proporção entre classes e permitindo avaliar o desempenho em dados não observados, enquanto no nível interno foi aplicada validação cruzada estratificada com três partições exclusivamente sobre os dados de treinamento de cada *fold*. Essa separação garante que o conjunto de teste permaneça independente durante o processo de ajuste, prevenindo estimativas excessivamente otimistas de desempenho [Berrar 2019].

3.9 Otimização hiperparâmetros

A otimização dos hiperparâmetros foi conduzida com o auxílio da biblioteca Optuna, baseada em estratégias de busca bayesiana, permitindo a seleção simultânea do algoritmo, de seus hiperparâmetros específicos e da estratégia de balanceamento, tornando o processo mais flexível e adaptativo ao comportamento dos dados [Akiba et al. 2019]. A função objetivo foi definida com base na média da área sob a curva *Receiver Operating Characteristic* – ROC (AUC) obtida na validação interna, por se tratar de uma métrica robusta em cenários com desbalanceamento de classes.

Durante a otimização, foram empregados mecanismos de interrupção antecipada (*pruning*), incluindo *Successive Halving*, *Median Pruner* e *Hyperband*, que permitem interromper execuções com baixo desempenho nas fases iniciais, reduzindo o custo computacional e concentrando recursos em regiões mais promissoras do espaço de busca [Li et al. 2018]. Ao final de cada iteração do ciclo externo, o melhor conjunto de hiperparâmetros foi utilizado para treinar o modelo final no conjunto completo de treinamento e avaliado no respectivo conjunto de teste, considerando métricas descritas na seção 3.10 a seguir, além do tempo de treinamento e armazenamento dos modelos finais.

3.10 Métricas de Avaliação e Análise do Threshold de Decisão

O desempenho do modelo foi avaliado por métricas alinhadas ao contexto de triagem clínica, incluindo sensibilidade (*recall*), especificidade, AUC-ROC e área sob a curva *Precision–Recall* (PRC), considerando que o custo clínico e social de falsos negativos (FN) na leptospirose é substancialmente superior ao de falsos positivos (FP). Nesse contexto, a análise do comportamento do modelo frente à variação do limiar (*threshold*) de decisão constituiu etapa central da avaliação, evidenciando reduções expressivas de FN em níveis inferiores ao limiar convencional de 0,5, região em que a sensibilidade é maximizada [Fawcett 2006; Reagan et al. 2022b].

Foram identificados *thresholds* nos quais FP e FN se tornam equivalentes ou minimamente discrepantes, adotando-se como critério adicional a maximização da sensibilidade, seguida do *F1-score*, de modo a priorizar a redução de falsos negativos sem comprometer excessivamente a precisão global do modelo. Essa abordagem permitiu selecionar pontos de corte mais adequados à detecção de casos suspeitos, assegurando equilíbrio entre segurança diagnóstica e viabilidade operacional nos sistemas de vigilância epidemiológica, em consonância com princípios da teoria de detecção de sinais e com recomendações para cenários de triagem clínica precoce [Fawcett 2006; Reagan et al. 2022b].

4. Análise e Discussão dos Resultados

4.1 Análise das variáveis demográficas, clínicas e epidemiológicas

Foi conduzida uma análise exploratória das variáveis demográficas, clínicas e epidemiológicas com o objetivo de caracterizar o perfil dos casos registrados no SINAN e identificar padrões associados à confirmação diagnóstica e à severidade clínica. Os resultados detalhados dessa análise, incluindo distribuições e gráficos descritivos, encontram-se apresentados no Apêndice C.

4.2 Custo computacional e impacto da seleção de variáveis

Na análise do custo computacional para a tarefa de classificação entre casos descartados e confirmados (Tabela D.3), observou-se que o algoritmo SVM apresentou, de forma consistente, os maiores tempos de processamento, especialmente nas abordagens sem seleção de variáveis, nas quais a maior dimensionalidade impactou diretamente o tempo de treinamento. Esse comportamento é esperado em modelos baseados em margens, que tendem a apresentar maior complexidade computacional em cenários com elevado número de atributos. Em contraste, os algoritmos LightGBM e *Random Forest* apresentaram tempos de processamento mais baixos e estáveis, mostrando-se mais adequados para aplicações em larga escala. Nesse cenário, a aplicação da seleção de variáveis contribuiu para uma redução expressiva do tempo de treinamento, evidenciando o impacto positivo da redução dimensional na eficiência computacional e na simplificação do espaço de busca durante a otimização dos modelos.

Na tarefa de classificação de severidade binária (Tabela D.4), observou-se redução consistente do tempo médio de treinamento nos modelos com seleção de variáveis. Esse comportamento foi verificado em todos os algoritmos avaliados, com destaque para o LightGBM, cujo tempo médio (segundos) foi reduzido de 15.1 ± 14.3 para 5.7 ± 7.0 , e para o SVM, que apresentou a maior diminuição absoluta, de 45.5 ± 26.1 para 19.1 ± 11.8 . Reduções semelhantes também foram observadas no XGBoost, de 12.4 ± 13.5 para 7.2 ± 7.4 , e no *Random Forest*, de 12.6 ± 13.1 para 7.5 ± 6.8 . Esses achados sugerem que, nesse contexto, a seleção de variáveis contribuiu para maior eficiência computacional, possivelmente em razão da diminuição do espaço de atributos processado e da simplificação do treinamento. Assim, os resultados indicam que a seleção de variáveis, além de atuar sobre a dimensionalidade do problema, pode também favorecer a redução do custo computacional, aspecto particularmente relevante em pipelines mais complexos.

4.3 Desempenho na validação interna e escolha de hiperparâmetros

A análise da validação interna evidenciou que o algoritmo LightGBM apresentou, de forma consistente, os maiores valores médios de AUC entre os modelos avaliados, superando XGBoost, SVM e *Random Forest* em praticamente todas as abordagens. Esse resultado sugere maior capacidade do LightGBM em capturar relações não lineares e interações entre variáveis, especialmente em bases com heterogeneidade e possível presença de ruído, como é o caso de dados epidemiológicos.

Na tarefa de classificação entre casos descartados e confirmados, os modelos atingiram valores de AUC superiores a 0.89, indicando elevada capacidade discriminativa (Tabela D.1). Observou-se que a abordagem sem seleção de variáveis apresentou desempenho superior àquela com redução de atributos, com AUC média em torno de 0.92 em comparação a aproximadamente 0.90 no cenário com seleção. Esse resultado sugere que, para essa tarefa, o conjunto completo de variáveis contém informações relevantes para a distinção entre classes, e que a remoção de atributos pode ter eliminado variáveis com contribuição incremental, ainda que não individualmente relevantes.

No cenário de severidade binária, os valores de AUC foram consideravelmente menores, situando-se em torno de 0.69 com seleção de variáveis e aproximadamente 0.71 sem seleção (Tabela D.2). Esse comportamento indica maior complexidade da tarefa, possivelmente associada à maior sobreposição entre os perfis clínicos das classes e à

presença de sinais menos discriminativos. Ainda assim, manteve-se o padrão observado anteriormente, com melhor desempenho dos modelos treinados sem seleção de variáveis.

4.4 Resultados finais na validação cruzada externa

Na avaliação final por validação cruzada externa, o algoritmo LightGBM manteve a superioridade observada na etapa de otimização de hiperparâmetros, apresentando os melhores resultados médios entre os modelos. Esse resultado reforça a consistência do modelo e sua capacidade de generalização, indicando que o desempenho não decorre de sobreajuste, mas de adequada adaptação às características da base epidemiológica.

Na classificação entre casos descartados e confirmados, a abordagem sem seleção de variáveis apresentou melhor desempenho global, com AUC média próxima de 0.93, além de ganhos em precisão e *F1-score* em relação ao cenário com seleção de variáveis (Tabela 7). Esse resultado sugere que o conjunto completo de atributos contém informações complementares relevantes para a confirmação diagnóstica, permitindo ao modelo capturar interações complexas entre variáveis clínicas, demográficas e epidemiológicas. Observa-se, contudo, leve *trade-off* entre precisão e *recall*, indicando comportamento mais conservador na identificação de casos positivos.

Tabela 7. Desempenho médio dos modelos na validação cruzada externa para classificação entre casos descartados e confirmados, avaliado pelas métricas Accuracy, Precision, Recall, F1-score e AUC, com e sem seleção de variáveis.

Abordagem	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>	<i>AUC</i>
Com Seleção	0.904 ± 0.002	0.761 ± 0.005	0.762 ± 0.005	0.761 ± 0.005	0.910 ± 0.004
Sem Seleção	0.911 ± 0.001	0.781 ± 0.002	0.779 ± 0.003	0.779 ± 0.002	0.931 ± 0.003

Na classificação de severidade binária, o desempenho foi inferior ao da confirmação diagnóstica, com AUC média em torno de 0.70 (Tabela 8). As diferenças entre os cenários com e sem seleção de variáveis foram pequenas em todas as métricas. Esse comportamento indica que a redução de dimensionalidade tem impacto limitado no desempenho, enquanto a tarefa apresenta maior complexidade intrínseca, associada à sobreposição entre perfis clínicos e menor separabilidade entre as classes.

Tabela 8. Desempenho médio dos modelos na validação cruzada externa para classificação de severidade clínica (grave vs. não grave), avaliado pelas métricas Accuracy, Precision, Recall, F1-score e AUC, com e sem seleção de variáveis.

Abordagem	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-score</i>	<i>AUC</i>
Com Seleção	0.652 ± 0.007	0.54 ± 0.08	0.55 ± 0.02	0.54 ± 0.01	0.69 ± 0.01
Sem Seleção	0.66 ± 0.01	0.56 ± 0.02	0.56 ± 0.01	0.56 ± 0.02	0.70 ± 0.02

Diante dos resultados, optou-se por conduzir as análises subsequentes utilizando o LightGBM integrado ao *pipeline* com seleção de variáveis. Embora a abordagem sem seleção apresente desempenho ligeiramente superior, a redução de dimensionalidade contribui para maior eficiência computacional, menor complexidade e maior interpretabilidade. Esses fatores são particularmente relevantes em aplicações em saúde

pública, nas quais escalabilidade e transparência são essenciais. Assim, a adoção do *pipeline* com seleção de variáveis representa um compromisso adequado entre desempenho preditivo e custo computacional.

4.5 Curvas ROC e Capacidade Discriminativa

As curvas ROC obtidas para cada *fold* externo evidenciam elevada capacidade discriminativa do modelo na classificação entre casos confirmados e descartados (Figura 1), com AUC em torno de 0.93 e curvas consistentemente afastadas da linha de não discriminação.

Para a severidade binária (Figura 1), observou-se desempenho mais moderado, com AUC próxima de 0.70. Embora as curvas permaneçam acima do aleatório, o menor afastamento indica maior dificuldade na separação entre classes, possivelmente devido à maior sobreposição dos perfis clínicos.




Figura 1. Curvas ROC validação externa LightGBM para casos confirmados (esquerda) e para severidade (direita).

De forma geral, os resultados indicam melhor desempenho na tarefa de confirmação diagnóstica em comparação à severidade, refletindo diferenças na complexidade dos desfechos. Assim como evidenciado no *fold* 1 (Figura 1), os resultados foram consistentes nos demais *folds* e pode ser encontrado no apêndice D (Figuras D.1 e D.2.) Ressalta-se que a curva ROC é independente do limiar de decisão, evidenciando que o desempenho decorre da capacidade de ordenação probabilística do modelo.

4.6 Curvas *Precision–Recall*

As curvas *Precision–Recall* (PRC) foram utilizadas como complemento à análise via curva ROC, por fornecerem avaliação mais informativa do desempenho na identificação da classe positiva em cenários desbalanceados. Essa abordagem é particularmente relevante na triagem clínica da leptospirose, na qual a correta identificação de casos positivos é prioritária.

Na Figura 2 são apresentadas as curvas *Precision–Recall* obtidas na validação cruzada externa para o modelo LightGBM na classificação entre casos confirmados e descartados. Observa-se comportamento consistente entre os *folds* (demais resultados na Figura D.3), com valores de AUPRC entre aproximadamente 0.81 e 0.82, indicando elevada capacidade do modelo em identificar corretamente casos confirmados sob diferentes partições dos dados. As curvas mostram manutenção de níveis elevados de precisão ao longo de ampla faixa de recall, com redução progressiva apenas próxima ao

recall máximo, comportamento esperado em cenários de triagem orientados à maximização da sensibilidade.

As curvas *Precision–Recall* para a classificação de severidade clínica (grave vs. não grave), também apresentadas nas Figuras 2 e D.4 (demais *folds*), exibiram valores de AUPRC entre aproximadamente 0.55 e 0.59, indicando desempenho preditivo moderado em comparação à tarefa de confirmação diagnóstica. Esse resultado é consistente com a maior complexidade da estratificação de severidade, caracterizada por maior sobreposição entre perfis clínicos e maior heterogeneidade das manifestações da doença.




Figura 2. Curvas *Precision–Recall* do modelo LightGBM em validação externa para casos confirmados (esquerda) e para severidade (direita).

A comparação entre as tarefas evidencia maior capacidade discriminativa do modelo na identificação de casos confirmados em relação à classificação de severidade clínica, padrão também observado na análise das curvas ROC. Assim como no *fold* 1 (Figura 2), os resultados foram consistentes nos demais *folds*, disponíveis no Apêndice D (Figuras D.3 e D.4).

4.7 Análise do Limiar de Decisão

A definição do limiar de decisão é etapa fundamental em modelos de classificação aplicados a contextos clínicos, especialmente em triagem epidemiológica, onde os custos dos erros são assimétricos. Na leptospirose, falsos negativos representam elevado risco clínico, pois podem atrasar diagnóstico e tratamento, aumentando a probabilidade de evolução para formas graves. Assim, foi analisado o comportamento das taxas de falsos positivos (FP) e falsos negativos (FN) em função do limiar de decisão, visando identificar valores de corte mais adequados ao contexto operacional da triagem clínica.

4.7.1 Ajuste do limiar para classificação de casos confirmados

A utilização de *thresholds* ajustados, em vez do valor convencional de 0.5, permite controlar explicitamente o *trade-off* entre sensibilidade e especificidade, aspecto relevante quando os custos dos erros são assimétricos. A Figura 3 apresenta a variação de FP e FN ao longo dos *thresholds* para cada partição da validação cruzada externa. Observa-se comportamento monotônico inverso entre as curvas: a redução do limiar diminui significativamente os falsos negativos, com aumento gradual dos falsos positivos, padrão esperado em modelos probabilísticos voltados à triagem.




Figura 3. Curvas de variação das quantidades de falsos positivos (FP) e falsos negativos (FN) em função do limiar de decisão para classificação entre casos descartados e confirmados de leptospirose ao longo das partições da validação cruzada externa.

De forma consistente entre os *folds* (Figura D.5), a interseção entre FP e FN ocorre em torno de 0.39–0.40, indicando estabilidade do ponto de equilíbrio. Dado o objetivo de priorizar a redução de falsos negativos, adotou-se *threshold* de 0.40, inferior a 0.5, aumentando a sensibilidade na identificação de casos confirmados. Esse ajuste é particularmente relevante em triagem clínica, onde a não detecção precoce pode levar a atraso terapêutico e maior risco de evolução grave.

4.7.2 Ajuste do limiar para classificação de severidade clínica

Procedimento análogo foi aplicado à classificação de severidade clínica. A Figura 4 apresenta a variação de FP e FN em função do limiar ao longo das partições da validação cruzada externa. Assim como na confirmação diagnóstica, observa-se comportamento monotônico inverso entre as curvas, no qual a redução do limiar diminui falsos negativos e aumenta falsos positivos, permitindo ajuste conforme estratégias de triagem e priorização de casos graves.




Figura 4. Curvas de falsos positivos e falsos negativos em função do limiar de decisão para severidade.

Entretanto, diferentemente da tarefa anterior, os pontos de interseção ocorreram próximos de 0.47–0.49 (Figura D.6), com consistência entre os *folds*, indicando menor deslocamento em relação ao limiar padrão e maior equilíbrio entre sensibilidade e especificidade. Esse comportamento sugere maior complexidade e menor separabilidade entre classes, associada à heterogeneidade clínica da doença. Ainda assim, pequenas reduções no limiar produzem diminuição relevante de falsos negativos, aspecto crítico em cenários clínicos. Assim, adotou-se *threshold* de 0.48, mantendo equilíbrio sem comprometer significativamente a precisão global do modelo.

4.7.3 Implicações clínicas do ajuste do limiar de decisão

A análise conjunta dos limiares de decisão para as tarefas de confirmação diagnóstica e classificação de severidade clínica evidencia que a utilização do valor convencional de 0.5 não representa necessariamente a escolha mais adequada em contextos de triagem epidemiológica. Observou-se que a tarefa de confirmação diagnóstica apresentou melhor desempenho com limiar próximo de 0.40, enquanto a classificação de severidade clínica manteve ponto de equilíbrio próximo de 0.48, refletindo diferenças estruturais entre os dois casos de classificação.

No contexto do Sistema Único de Saúde, a adoção de limiares ajustados permite que o modelo opere como ferramenta de apoio à triagem clínica, favorecendo a identificação precoce de casos com maior probabilidade de confirmação ou evolução desfavorável, ao mesmo tempo em que mantém impacto operacional controlado sobre o volume de falsos positivos. Dessa forma, a análise do comportamento das curvas de falsos positivos e falsos negativos reforça o caráter aplicado do modelo proposto, evidenciando seu potencial como instrumento quantitativo de suporte à tomada de decisão em cenários reais de saúde pública.

4.8 Calibração Probabilística

A calibração probabilística do modelo foi avaliada com o objetivo de verificar a correspondência entre probabilidades previstas e frequências observadas dos desfechos, aspecto central em aplicações clínicas e epidemiológicas baseadas em estimativas de risco. As curvas de calibração obtidas na validação cruzada externa evidenciaram boa concordância entre probabilidades previstas e observadas na classificação de casos descartados e confirmados (Figura 5), mantendo-se próximas da linha de calibração perfeita em todos os *folds* (Figura D.7), o que indica adequado ajuste probabilístico do modelo aos dados. Comportamento análogo foi observado na classificação de severidade clínica (Figura 5), com consistência entre os *folds* (Figura D.8) e alinhamento com a linha de referência ideal, mesmo diante da maior complexidade da tarefa de estratificação.




Figura 5. Curvas de calibração do modelo LightGBM em validação externa para casos confirmados (direita) e severidade (esquerda).

Do ponto de vista prático, a boa calibração implica que as probabilidades estimadas podem ser interpretadas diretamente como risco clínico. Assim, uma probabilidade de 70% atribuída pelo modelo para confirmação diagnóstica ou evolução para quadro grave corresponde, em termos esperados, à ocorrência do desfecho em aproximadamente 70% dos casos nessa faixa.

Do ponto de vista prático, esse comportamento indica que as probabilidades estimadas podem ser interpretadas diretamente como risco clínico, permitindo, por exemplo, associar uma probabilidade prevista de 70% a uma ocorrência esperada semelhante do desfecho nessa faixa. Essa propriedade é particularmente relevante em cenários de triagem clínica e vigilância epidemiológica, reforçando o potencial do modelo como ferramenta de apoio à decisão no contexto do Sistema Único de Saúde.

4.9 Variáveis Explicativas e Aplicabilidade do Modelo na Triagem do SUS

A importância das variáveis foi estimada pela média e desvio padrão na validação cruzada externa, permitindo avaliar relevância e estabilidade dos preditores [Berrar 2019]. O estudo sobre dados do SINAN com casos de leptospirose de 2015–2024 evidenciam caráter multifatorial da doença, envolvendo fatores ocupacionais, socioeconômicos, clínicos e ambientais [Brasil. Ministério da Saúde 2016].

4.9.1 Importância das variáveis na classificação de casos confirmados

Na classificação entre casos descartados e confirmados, observou-se predominância de variáveis sociodemográficas, clínicas e ambientais (Tabela D.5). A variável referente a ocupação do paciente (ID_OCUPA_N) apresentou a maior importância média (211.25 ± 5.68), evidenciando a relevância da exposição amplamente descrita como fator de risco para leptospirose.

Destacam-se também o nível de escolaridade e a idade do paciente, reforçando o papel de determinantes socioeconômicos e demográficos, reforçando a análise exploratória feita na seção 4.1.1. Do ponto de vista clínico, CLI_ICTERI e CLI_PANTUR apresentaram elevada relevância, sendo compatíveis com manifestações clássicas da doença, especialmente a icterícia como marcador de quadros mais evidentes [Brasil 2014]. Variáveis ambientais, como CON_AMBIEN e CON_AREA, também contribuíram de forma significativa, evidenciando a influência do contexto socioambiental. Variáveis derivadas, como vulnerabilidade_social e periodo_chuvoso, embora com menor magnitude, reforçam a capacidade do modelo em capturar efeitos contextuais [Bohm 2024].

4.9.2 Importância das variáveis na classificação de severidade clínica

Na classificação da severidade, observa-se maior destaque para variáveis geográficas e clínicas (Tabela D.6). A variável SG_UF apresentou a maior importância (91.75 ± 6.50), sugerindo influência de heterogeneidades regionais, infraestrutura sanitária e padrões ambientais de exposição [Costa et al. 2015; Da Saúde 2023]. Entre as variáveis clínicas, CLI_PROST, CLI_CONGES e CLI_PANTUR apresentaram maior importância, indicando o papel central das manifestações sistêmicas na determinação da gravidade, enquanto variáveis de exposição e antecedentes, como ANT_CB_SIN e ANT_CB_LAM, reforçam a contribuição do contato com ambientes contaminados e reservatórios sinantrópicos na progressão para quadros mais graves [Brasil 2014; Li et al. 2022; Bohm 2024]. Observou-se ainda influência de fatores demográficos, socioeconômicos e ambientais, com destaque para a idade (NU_IDADE_N), além de CS_ESCOL_N e ID_OCUPA_N, embora com menor magnitude relativa, enquanto variáveis como CON_AREA, CON_AMBIEN e indicadores de contato ambiental mantiveram relevância

na dinâmica de agravamento da doença, em consonância com achados exploratórios anteriores [Bohm 2024].

A análise comparativa entre as tarefas evidencia distinção estrutural nos mecanismos subjacentes: a confirmação diagnóstica é majoritariamente determinada por fatores de exposição e condições socioeconômicas, enquanto a severidade está mais diretamente associada a manifestações clínicas e ao contexto assistencial. Tal comportamento é consistente com a literatura epidemiológica, reforçando a robustez do modelo e seu potencial aplicado como ferramenta de apoio à decisão na triagem clínica no Sistema Único de Saúde [Berrar 2019; Brasil 2014; Da Saúde 2023].

5. Conclusão

Este estudo investigou o potencial da aplicação de técnicas de aprendizado de máquina sobre dados do Sistema de Informação de Agravos de Notificação (SINAN), no âmbito do Sistema Único de Saúde, para apoiar a confirmação diagnóstica e a estratificação da severidade clínica em casos suspeitos de leptospirose, diante da persistência da doença como problema de saúde pública em contextos de vulnerabilidade socioambiental e limitações estruturais para identificação precoce de casos graves.

Os resultados evidenciaram elevada capacidade discriminativa do modelo LightGBM na tarefa de classificação entre casos confirmados e descartados, com AUC próxima de 0.93 em validação cruzada externa, além de desempenho moderado na predição da severidade clínica ($AUC \approx 0.70$). A análise conjunta das curvas ROC e Precision–Recall demonstrou consistência entre os *folds*, indicando adequada capacidade de generalização. Adicionalmente, a análise de sensibilidade ao limiar de decisão evidenciou que *thresholds* inferiores ao valor convencional de 0.5 são mais apropriados ao contexto de triagem clínica, ao priorizar a redução de falsos negativos, aspecto crítico em doenças de evolução potencialmente grave.

Como perspectiva de evolução, destaca-se a incorporação de variáveis ambientais, climáticas e territoriais para ampliar a capacidade preditiva, bem como a integração do modelo em uma arquitetura baseada em sistemas multiagentes voltadas à interpretação de relatos clínicos não estruturados e extração automática de atributos relevantes. Nesse arranjo, o modelo permanece como núcleo analítico, enquanto agentes especializados viabilizam a organização das informações, a estratificação de risco e o apoio à decisão clínica, favorecendo sua aplicabilidade prática no contexto do SUS.

Do ponto de vista aplicado, os achados indicam que o modelo constitui uma estratégia promissora para apoiar a identificação precoce de casos com maior probabilidade de confirmação diagnóstica. Não obstante, o estudo apresenta limitações inerentes ao uso de dados secundários de vigilância epidemiológica, incluindo incompletude, inconsistências no preenchimento e heterogeneidade na qualidade dos registros entre regiões e períodos.

Declaração: Informamos que, para o refinamento linguístico e estilístico deste texto, foi utilizado um modelo de linguagem de grande porte (LLM), chatGPT. O conteúdo técnico, científico e factual permaneceu sob responsabilidade exclusiva dos autores, sendo o LLM empregado apenas como ferramenta auxiliar de revisão e aprimoramento da escrita.

Referências

Akiba, T., Sano, S., Yanase, T., Ohta, T. and Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*.

Berrar, D. (2019). Cross-validation.

Bohm, B. C. (2024). Avaliação de dados do sistema de saúde e elaboração de ferramentas de triagem. p. 91–105.

Brasil (16 mar 2014). Leptospirose: diagnóstico e manejo clínico.

Brasil. Ministério da Saúde (16 mar 2016). Sistema de Informação de Agravos de Notificação (SINAN): normas e rotinas.

Brasil. Ministério da Saúde (16 mar 2023). Sistema Único de Saúde (SUS): estrutura, princípios e funcionamento Sistema Único de Saúde (SUS): estrutura, princípios e funcionamento.

Brasil. Ministério da Saúde (16 mar 2024). Guia de vigilância em saúde: volume 3.

Breiman, L. (2001). Random forests. *Machine learning*, v. 45, n. 1, p. 5–32.

Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*.

Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine learning*, v. 20, n. 3, p. 273–297.

Costa, F., Hagan, J. E., Calcagno, J., et al. (2015). Global morbidity and mortality of leptospirosis: a systematic review. *PLoS neglected tropical diseases*, v. 9, n. 9, p. e0003898.

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern recognition letters*, v. 27, n. 8, p. 861–874.

Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of statistics*, p. 1189–1232.

Galdino, G. S., De Sandes-Freitas, T. V., De Andrade, L. G. M., et al. (2023). Development and validation of a simple machine learning tool to predict mortality in leptospirosis. *Scientific Reports*, v. 13, n. 1, p. 4506.

Guyon, I. and Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of machine learning research*, v. 3, n. Mar, p. 1157–1182.

He, H. and Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, v. 21, n. 9, p. 1263–1284.

Ke, G., Meng, Q., Finley, T., et al. (2017). Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, v. 30.

Kraskov, A., Stögbauer, H. and Grassberger, P. (2004). Estimating mutual information. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, v. 69, n. 6, p. 66138.

Li, D., Liang, H., Yi, R., et al. (2022). Clinical characteristics and prognosis of patient with leptospirosis: A multicenter retrospective analysis in south of China. *Frontiers in Cellular and Infection Microbiology*, v. 12, p. 1014530.

Li, L., Jamieson, K., DeSalvo, G., Rostamizadeh, A. and Talwalkar, A. (2018). Hyperband: A novel bandit-based approach to hyperparameter optimization. *Journal of machine learning research*, v. 18, n. 185, p. 1–52.

Lima, C. R. de A., Schramm, J. M. de A., Coeli, C. M. and Silva, M. E. M. Da (2009). Revisão das dimensões de qualidade dos dados e métodos aplicados na avaliação dos sistemas de informação em saúde. *Cadernos de saúde pública*, v. 25, p. 2095–2109.

Ministério da Saúde (2026). DATASUS-TABNET.

Mooney, S. J. and Pejaver, V. (1 apr 2018). Big Data in Public Health: Terminology, Machine Learning, and Privacy. *Annual Review of Public Health*, v. 39, n. 1, p. 95–112.

Pappas, G., Papadimitriou, P., Siozopoulou, V., Christou, L. and Akritidis, N. (2008). The globalization of leptospirosis: worldwide incidence trends. *International journal of infectious diseases*, v. 12, n. 4, p. 351–357.

Reagan, K. L., Deng, S., Sheng, J., et al. (2022a). Use of machine-learning algorithms to aid in the early detection of leptospirosis in dogs. *Journal of Veterinary Diagnostic Investigation*, v. 34, n. 4, p. 612–621.

Reagan, K. L., Deng, S., Sheng, J., et al. (2022b). Use of machine-learning algorithms to aid in the early detection of leptospirosis in dogs. *Journal of Veterinary Diagnostic Investigation*, v. 34, n. 4, p. 612–621.

Reinheimer, I. C., Corrêa-Dos-Santos, A., Carlan, B. D., et al. (2025). IMPACTO DO BALANCEAMENTO DE DADOS NA PERFORMANCE DE MODELOS DE MACHINE LEARNING PARA PREDIÇÃO DE OBITO DE PACIENTES EM HEMODIALISE NO SUS. *Braz. J. Nephrol.*, v. 47, n. 3 Suppl. 1, p. S501.

Sawesi Suhila and Jadhav, A. and R. B. (may 2025). Machine Learning and Deep Learning Techniques for Prediction and Diagnosis of Leptospirosis: Systematic Literature Review. *JMIR Med Inform*, v. 13, p. e67859.

Senter, H. F. (2008). *Applied linear statistical models*. . Taylor & Francis.

Silva, A. F. Da, Figueiredo, K., Falcão, I. W. S., et al. (2024). Study of machine learning techniques for outcome assessment of leptospirosis patients. *Scientific Reports*, v. 14, n. 1, p. 13929.

Silva, L. P. Da, Moreira, C. M. M., Amorim, M. H. C., Castro, D. S. De and Zandonade, E. (2014). Avaliação da qualidade dos dados do Sistema de Informações sobre Nascidos Vivos e do Sistema de Informações sobre Mortalidade no período neonatal, Espírito Santo, Brasil, de 2007 a 2009. *Ciência & Saúde Coletiva*, v. 19, p. 2011–2020.

Apêndice – Repositório do Projeto

O código-fonte, bem como os artefatos utilizados no desenvolvimento deste trabalho, estão disponíveis publicamente em repositório GitHub. O material inclui scripts de processamento de dados, análises estatísticas e demais componentes necessários para a reprodução dos resultados apresentados neste estudo.

O repositório intitula-se *Ita-project: análises leptospirose pysus* e foi desenvolvido por Ana Carolyne Pereira e Diego Pereira Lima, com publicação em abril de 2026. A versão utilizada neste trabalho corresponde à branch *feature/leptospirose-analises-pysus*.

O acesso ao repositório pode ser realizado por meio do seguinte link:

<https://github.com/diego-pereira-de-lima/ita-project/tree/feature/leptospirose-analises-pysus>

Adicionalmente, os apêndices complementares deste trabalho encontram-se disponíveis no mesmo repositório, contemplando:

- Apêndice A — Dicionário das Variáveis Seleccionadas
- Apêndice B — Espaço de busca dos hiperparâmetros
- Apêndice C — Análise Exploratória das Variáveis do SINAN
- Apêndice D — Resultados de validação interna e importância de variáveis

Esses materiais podem ser acessados por meio do seguinte endereço:

<https://github.com/diego-pereira-de-lima/ita-project/tree/feature/leptospirose-analises-pysus/artigo/apendices>